INTERNATIONALE HOCHSCHULE

Projekt: Data Science Use Case

(DLMDWPDSUC01)

Optimierung eines ÖPNV-Liniennetzes

(Finalisierungsphase)

Sascha Seefelder

UPS10781768

Tutor: Sahar Qadaan

Datum: 18.05.2026

Inhaltsverzeichnis

1. Szenario 1
2. Machine Learning Canvas 3
2.1 Value Proposition 3
2.2 Prediction Task 4
2.3 Decisions 5
2.4 Impact Simulation 6
2.5 Making Predictions 8
2.6 Data Collection 9
2.7 Data Sources 10
2.8 Building Models 11
2.9 Features 13
2.10 Monitoring 14
3. Grafischer ML Canvas 16
4. Pitch Deck 17
Literaturverzeichnis 18

1. Szenario

Die benachbarten Städte Ulm und Neu-Ulm haben zusammen etwa 186.000 Einwohner (Stadt Neu-Ulm, o. J.; Beinhölzl, o. J.) und begrüßen jährlich 630.000 Touristen *(Klemm, 2025)*. Der öffentliche Personennahverkehr (ÖPNV) wird betrieben durch die SWU Verkehr GmbH, eine Tochterfirma der Stadtwerke Ulm/Neu-Ulm GmbH (SWU). Die SWU Verkehr verfügt über 2 Straßenbahnlinien und insgesamt 18 Stadtbuslinien, 6 davon Nachtbuslinien. Insgesamt werden pro Jahr 41,3 Millionen Fahrgäste befördert (SWU, 2025).

Die SWU Verkehr GmbH steht vor mehreren Herausforderungen. Eine Grossbaustelle am Ehinger Tor wird zwischen August 2026 und Ende 2027 einen der wichtigsten Knotenpunkte des ÖPNV in der Stadt lahmlegen (Stadt Ulm, o. J.). Das kontinuierliche Wachstum der Wissenschaftsstadt am Oberen Eselsberg erfordert eine entsprechende Anbindung. Ebenso werden die geplanten Wohngebiete Dichterviertel, Wiley und Science Park angebunden werden müssen. (Von Poll, o. J.). Die Großbaustellen Blaubeurer Ring und Gänstorbrücke führen zu Hauptverkehrszeiten zu Staus die einen zeitgerechten Betrieb auf den Linien 6 und 10 unmöglich machen und zu Fahrtausfällen führen. Gleichzeitig sind Fahrten in die Gewerbegebiete Donautal und Ulm-Nord den Großteil des Tages komplett leer. Angesichts der anstehenden Landesgartenschau im Jahr 2030 und der kommenden Großbaustellen Adenauerbrücke und B 10-Neubau müssen diese Probleme dringend gelöst werden.

Die bisherige Netzplanung stützt sich primär auf historische Fahrgastzählungen und statische Liniennetze. Die entscheidende Informationslücke besteht in der Unfähigkeit dieser Modelle, dynamische Faktoren wie kurzfristige Verkehrsverlagerungen durch Baustellen oder das rapide Wachstum von Stadtteilen in Echtzeit zu quantifizieren. Planer wissen zwar, dass ein Problem existiert, verfügen aber über keine präzise Datengrundlage, um den exakten Bedarf pro Streckensegment vorherzusagen. Dies beinhaltet auch neue Haltestellen zu schaffen, wo sie gebraucht werden, und die Linienverläufe zu überdenken.

Als Datenquellen stehen bereits zur Verfügung die eigene App zur Fahrplanauskunft und die des regionalen Verkehrsverbundes Donau Iller Nahverkehrsverbund GmbH (DING). Des Weiteren gibt es eine Webseite mit traditioneller Fahrplanauskunft und interaktiver Echtzeitauskunft. Diese Quellen können sowohl Suchanfragen protokollieren als auch, bei akzeptierter Datenschutzerklärung, den GPS-Standort zum Zeitpunkt der Suchanfrage speichern. Fahrkarten, die in den jeweiligen Apps oder in den Fahrzeugen erworben werden, geben Aufschluss über Start und Ziel der Fahrten. Außerdem sind sehr häufig im Innenraum der Fahrzeuge Sensoren verbaut, die aktuelle Fahrgastzahlen bestimmen (Becker, 2026). Informationen über Linienverläufe und Fahrpläne liefern öffentlich verfügbare GTFS-Daten (General Transit Feed Specification).

Das Ziel der Optimierungen ist es, die Anzahl Fahrten mit hoher Auslastung zu minimieren. Laut dem Verband Deutscher Verkehrsunternehmen (VDV) besteht eine hohe Auslastung bei einer Belegung über 75% der Gesamtkapazität des Fahrzeuges, bzw. laut dem Forschungsprojekt U-hoch-3 der Universität Kassel bei 100% Belegung aller Sitzplätze des Fahrzeuges (Saake et al., 2024). Gleichzeitig sollen auch Fahrten mit einer niedrigen Auslastung von weniger als 50% der Gesamtkapazität minimiert werden (Saake et al., 2024). Ein weiteres Ziel ist es, die Anzahl der benötigten Umstiege auf 1 zu begrenzen. Der

geplante datengetriebene Ansatz transformiert die vorhandenen Rohdaten in eine prädiktive Entscheidungsgrundlage. Anstatt nur auf vorhandene Überlastungen zu reagieren, ermöglicht ein Machine Learning-Modell eine proaktive Kapazitätssteuerung. Durch die Verbindung von Echtzeit-Verkehrsdaten mit demografischen Wachstumsprognosen wird die Diskrepanz zwischen statischem Angebot und der tatsächlichen Nachfrage beseitigt. So wird aus einer vagen Einschätzung über Linienbedarfe eine exakte, datenbasierte Prognose für operative und strategische Entscheidungen.

2. Machine Learning Canvas

2.1 Value Proposition

Das aktuelle Liniennetz des öffentlichen Personenverkehrs in Ulm steht vor der Herausforderung, dass es historisch gewachsen ist und nur noch bedingt auf die dynamischen Veränderungen einer modernen Stadtlandschaft reagieren kann. Dies führt zu einer Diskrepanz zwischen dem tatsächlichen Mobilitätsbedarf der Bürger und dem bereitgestellten Angebot.

Konkret können wir drei Kernprobleme identifizieren. Linienabschnitte mit geringer Auslastung bei gleichzeitiger Überlastung anderer Verbindungen. Diese ineffiziente Ressourcenverteilung führt zu einer Verschwendung von Betriebsmitteln und Qualitätsverlust für den Fahrgast. Außerdem erhöhen unvorteilhafte Taktungen und häufige Umstiege die Reisezeit im Vergleich zum Individualverkehr drastisch. In einer Phase infrastruktureller Baumaßnahmen droht der ÖPNV durch diesen Attraktivitätsverlust zunehmend seine Rolle als zuverlässiges Rückgrat der Mobilität zu verlieren. Letztendlich stützt sich die Verkehrsplanung bisher auf statische oder veraltete Datenmodelle. Kurzfristige Ereignisse, saisonale Schwankungen oder neue Wohn- und Gewerbegebiete können so nicht präzise in die Netzgestaltung einfließen.

Ziel dieses Projektes ist es, die Planungsgrundlage von einer strikt angebotsorientierten Logik hin zu einer bedarfsorientierten Logik zu transformieren. Durch eine präzise Abstimmung der Fahrtangebote auf die tatsächliche Nachfrage reduzieren wir Leerfahrten und optimieren den Einsatz von Fahrzeugflotte und Personal. Dies fördert die Wirtschaftlichkeit in Zeiten steigender Energiekosten und knapper öffentlicher Budgets. Für den Fahrgast liegt der primäre Nutzen in einer spürbaren Komfortsteigerung. Für Fahrgäste bedeutet ein optimiertes Netz kürzere Reisezeiten durch Minimierung von Umsteigevorgängen und Wartezeiten, Verlässlichkeit durch Sicherstellung ausreichender Kapazitäten auf stark frequentierten Routen und Erreichbarkeit durch eine verbesserte Anbindung von Randgebieten und neuen Stadtteilen basierend auf realem Nutzerverhalten. Des Weiteren schafft dieses Projekt die Grundlage für ein System, das in der Lage ist, auf Veränderungen wie etwa Großveranstaltungen oder Großbaustellen proaktiv zu reagieren. Diese Flexibilität gibt Entscheidungsträgern die nötige Handlungssicherheit.

Langfristig ist das Ziel dieses Projekts, die Wahl des Verkehrsmittels in Richtung öffentlicher Nahverkehr zu verschieben. Nur durch eine Verkehrsplanung, die sich nahtlos und ohne Reibungsverluste in den Alltag der Bürger integriert, lässt sich sowohl die urbane Lebensqualität als auch unser wirtschaftlicher Erfolg dauerhaft sichern.

2.2 Prediction Task

Die zentrale Aufgabe ist es, eine Regressionsanalyse zur Vorhersage der kurz- bis mittelfristigen Fahrgastnachfrage auf Segmentebene des Liniennetzes zu erstellen. Das Ziel dabei ist es für jedes Fahrzeug, Bus oder Strassenbahn, auf jedem Teilstück einer Linie zu jedem Zeitpunkt die zu erwartende Auslastung zu prognostizieren. Diese Vorhersage dient als Grundlage, um die bisher angebotsorientierte Planung durch ein bedarfsorientiertes Modell zu ersetzen.

Die Vorhersage soll getroffen werden für jedes Streckensegment, also den Abschnitt zwischen zwei Haltestellen, und zu jeder Zeit, wobei die Zeitintervalle 10 Minuten betragen, um sowohl Spitzenbelastungen zu Hauptverkehrszeiten als auch saisonale Schwankungen präzise bestimmen zu können.

Das Ziel der Vorhersage ist die relative Fahrgastkapazität in Prozent beziehungsweise die absolute Personenzahl pro Fahrzeug. Basierend auf den Vorgaben des VDV und U-hoch-3 wird das Modell darauf trainiert die Auslastung möglichst zwischen den Grenzwerten für eine hohe und niedrige Auslastung zu halten, konkret entspricht dies zwischen 50% und 75% der Gesamtkapazität und weniger als 100% Sitzplatzbelegung. Ergänzend wird die Wahrscheinlichkeit für spezifische Start-Ziel-Kombinationen vorhergesagt, um die Anzahl nötiger Umsteigevorgänge zu minimieren.

Die Prognose soll sowohl kurz- als auch mittelfristig erfolgen. Vorhersagen für die nächsten 1 bis 4 Stunden sind entscheidend, um zeitnah auf Staus reagieren zu können und Fahrtausfällen entgegenzuwirken. Prognosen für die nächsten 3 bis 6 Monate ermöglichen die Planung von Ersatzverkehr und Linienanpassungen rechtzeitig zu den jeweiligen Fahrplanumstellungen. Die Vorhersagen können am Ende jeder Fahrt mit Hilfe der Zählsensoren in den Fahrzeugen und Ticketverkäufen durch Automaten im Fahrzeug und der Apps im Verkehrsverbund validiert werden.

Um eine hohe Präzision der Vorhersage zu gewährleisten, müssen auch externe Ereignisse in Betracht gezogen werden. Insbesondere betrifft dies aktuelle und geplante Baustellen im Stadtgebiet, die demografische Entwicklung wie das Wachstum und Erschließung von Wohngebieten und anstehende Großereignisse wie beispielsweise die Landesgartenschau 2030.

2.3 Decisions

Die operativen Entscheidungen basieren auf der Kurzfristvorhersage für die nächsten 1 bis 4 Stunden und zielen darauf ab, die Servicequalität zu erhalten, trotz unvorhergesehener Ereignisse wie Staus oder Fahrtausfällen. Bei einer prognostizierten hohen Auslastung über 75% der Gesamtkapazität auf kritischen Segmenten wird die Entscheidung getroffen, Verstärkerfahrten oder größere Fahrzeugeinheiten, wie Gelenkbusse statt Standardbussen, einzusetzen. Sollten Echtzeit-Verkehrsdaten erhebliche Verspätungen prognostizieren, entscheidet das System über alternative Ausweichrouten oder das Vorziehen von Wendemanövern, um den Takt in nicht betroffenen Streckenabschnitten zu stabilisieren. Außerdem ist es wichtig, den Fahrgast rechtzeitig zu informieren und alternative Streckenvorschläge zu machen, noch bevor dieser an einer überlasteten Haltestelle eintrifft.

Sowohl taktische als auch strategische Entscheidungen nutzen die Prognose für die nächsten 3 bis 6 Monate, um das Netz strukturell an den tatsächlichen Bedarf anzupassen. So müssen taktische Entscheidungen getroffen werden, welche Linienabschnitte durch Großbaustellen, wie zum Beispiel dem Umbau des Knotenpunktes Ehinger Tor, durch Schienenersatzverkehr oder Streckenumleitungen kompensiert werden müssen. Werden Liniensegmente identifiziert, die dauerhaft eine Auslastung von unter 50% aufweisen, wie beispielsweise Gewerbegebiete zu bestimmten Zeiten, so wird die Entscheidung getroffen, den Linientakt entsprechend auszudünnen beziehungsweise auf On-Demand-Angebote umzustellen. Gleichzeitig führt die Prognose einer dauerhaft hohen Auslastung über 75% der Gesamtkapazität, wie in Wachstumsgebieten, zu der Entscheidung neuer Haltestellen, Linienverlängerungen oder Verdichtung des Linientaktes. Ebenso wird die Prognose für strategische Entscheidungen zur Flottenplanung herangezogen. Es wird entschieden, in welche Fahrzeugtypen investiert wird, um das Ziel von maximal einem Umsteigevorgang bei optimaler Energieeffizienz, durch Vermeidung von Leerfahrten, zu erreichen.

Der Entscheidungsprozess folgt definierten Schwellenwerten basierend auf den Konfidenzintervallen der Impact Simulation (siehe Kapitel 2.4 Impact Simulation). Personalverfügbarkeit, gesetzliche Ruhezeiten und Fahrzeugverfügbarkeit erhöhen die Komplexität der Planungen im Personennahverkehr deutlich, was eine menschliche Validierung notwendig macht. Das System dient nur als Werkzeug zur Entscheidungsfindung, die finale Entscheidung liegt weiterhin bei den Verkehrsdisponenten. Wesentliche Parameter für diese Entscheidungen sind die Definitionen niedriger und hoher Auslastung bei 50% beziehungsweise 75% der Gesamtkapazität, sowieso das Konfidenzintervall für die zeitliche Stabilität der Vorhersage.

2.4 Impact Simulation

Was sind die Kosten- oder Gewinnwerte für korrekte bzw. falsche Entscheidungen? Es wird definiert, welche Daten zur Simulation vor dem Einsatz genutzt werden, was die Kriterien für ein Deployment sind und ob es Fairness-Beschränkungen gibt.

Bevor das Modell operativ in die Leitstellensysteme integriert werden kann, muss simuliert werden, welche finanziellen und qualitativen Auswirkungen korrekte beziehungsweise fehlerhafte Vorhersagen auf die SWU Verkehr GmbH und den Fahrgast haben. Die Bewertung des Modells erfolgt über eine Kosten-Nutzen-Matrix, die sowohl die betriebswirtschaftliche Perspektive der SWU als auch die Servicequalität der Fahrgäste berücksichtigt. Erläuterungen zu dieser Kosten-Nutzen-Matrix sind der folgenden Tabelle zu entnehmen:

Modell-Prognose	**reale Situation**	**Betriebswirtschaftliche Auswirkung**	**Entscheidung/Regel für die Leitstelle**
True Positive Überlastung vorhergesagt und eingetroffen	Fahrzeug überlastet (>75%)	Optimale Kapazität, zufriedene Kunden, Takt gesichert.	Verstärkerfahrt wird freigegeben, wenn die prognostizierte Wahrscheinlichkeit P(Auslastung>75%) über 80% liegt.
False Positive Überlastung vorhergesagt, aber leer	Fahrzeug unterbelegt (<50%)	komplette Fehlplanung, Kosten von ca. 150-200€ pro unnötige Betriebsstunde für Personal/Energie.	Um Fehlplanungskosten zu minimieren, wird ein Gelenkbus erst geschickt, wenn die Vorhersage über 3 aufeinanderfolgende 10-Minuten-Intervalle stabil bleibt.
False Negative keine Überlastung vorhergesagt, aber voll	Fahrzeug überlastet (>75%)	Qualitätsverlust, Imageschaden, Einnahmeverlust durch verpasste Fahrgäste.	Bei kritischen Linien und zu Hauptverkehrszeiten, wird der Schwellenwert für Warnungen P(Auslastung>75%) auf 65% gesenkt, um das Risiko unvorhergesehener Überfüllung zu minimieren.
True Negative Leerfahrt vorhergesagt und eingetroffen	Fahrzeug unterbelegt (<50%)	Ressourcen gespart durch proaktive Taktausdünnung oder Umstellung aus On-Demand.	Takt wird temporär halbiert, wenn die prognostizierte Auslastung mit einer Sicherheit von 90% unter der 50%-Marke liegt.

Um die praktische Steuerbarkeit für die Disponenten zu schärfen, wird die Impact Simulation an eine harte mathematische Entscheidungsregel gekoppelt. Das System operiert nicht mit bloßen Punktprognosen, sondern mit Wahrscheinlichkeitsdichten. Eine operative Maßnahme wird nur dann automatisch vorgeschlagen, wenn der Erwartungswert der Auslastung über 75% liegt und gleichzeitig die Wahrscheinlichkeit dafür über 80% beträgt. Durch diese

80%-Hürde wird sichergestellt, dass die Kosten für False Positives, also unnötige Leerfahrten bei vorhergesagter Überfüllung, in einem optimalen Verhältnis zu den Kosten bei Service-Zusammenbrüchen (False Negatives) stehen.

Um das Risiko vor dem tatsächlichen Einsatz zu minimieren, werden Offline-Simulationen auf Basis historischer Daten der Fahrkartenverkäufe sowie der Zählsensoren durchgeführt. Zunächst wird simuliert, wie das Modell vergangene Stresssituationen wie plötzliche Staus oder Großveranstaltungen prognostiziert hätte. Nach dieser Laborphase wird das System in einem Parallellauf für den aktuellen Betrieb getestet, diese Vorhersagen werden allerdings nicht direkt in Entscheidungen umgesetzt. Die Verkehrsdisponenten vergleichen die Vorschläge des Systems mit ihren eigenen tatsächlichen Entscheidungen und den Sensordaten aus den Fahrzeugen.

Ein tatsächlicher Einsatz des Modells erfolgt nur, nachdem in diesem Parallellauf definierte Schlüsselkennzahlen über einen Zeitraum von mindestens 4 Wochen stabil erreicht werden. Das System muss die Auslastung korrekt den Kategorien "hohe Auslastung” und “niedrige Auslastung" zuordnen und dabei einen F1-Score von mindestens 0,85 erreichen, hierfür wird das harmonische Mittel von Präzision und Sensitivität der Vorhersage verwendet. Um Fehlplanungen in der Leitstelle zu vermeiden, müssen die Vorhersagen für die kommenden 1 bis 4 Stunden ein Konfidenzniveau von 90% erreichen. Die finale Entscheidung über einen Einsatz liegt bei den Verkehrsdisponenten und der Leitstelle. Ihre fachliche Expertise erlaubt es ihnen, die Plausibilität und Effektivität der Vorschläge zu bewerten, dies ist ein zwingendes Freigabekriterium.

Es muss sichergestellt werden, dass die Optimierungen nicht zu Lasten von vulnerablen Gruppen oder weniger stark frequentierten Stadtteilen gehen. Selbst bei einer vorhergesagten Auslastung von 0% darf eine Taktausdünnung nicht zu einer Unterschreitungen der im Regionalisierungsgesetz und Personenbeförderungsgesetz vorgeschriebenen Grundversorgung führen (§1 Abs. 1 RegG, 2026, §8 Abs. 3 PBefG, 2026).

2.5 Making Predictions

Im Rahmen der operativen und strategischen Steuerung des Ulmer Liniennetzes ist die Art und Weise, wie Vorhersagen generiert werden, entscheidend für die Reaktionsfähigkeit der SWU Verkehr GmbH. Um sowohl kurzfristige Störungen als auch langfristige Planungen abzudecken, implementieren wir ein hybrides Vorhersagesystem. Um den unterschiedlichen zeitlichen Anforderungen gerecht zu werden, wird das System hierfür in zwei parallele Stränge unterteilt. Für kurzfristige operative Entscheidungen im Bereich 1 bis 4 Stunden werden Vorhersagen in Echtzeit erstellt. Dies ist zwingend notwendig, um auf plötzliche Fahrtausfälle oder Kapazitätsengpässe reagieren zu können. Eine hohe Frequenz der Vorhersagen ist ausschlaggebend für eine hohe operative Relevanz der Entscheidungen. Die Vorhersagen für die unmittelbare Auslastung der Fahrzeuge werden alle 5 Minuten aktualisiert. Für die taktischen und strategischen Planungen im Bereich 3 bis 6 Monate werden Vorhersagen im Batch-Verfahren generiert. Hierfür werden wöchentlich großflächige Simulationen durchgeführt, um das Liniennetz auf Basis der neuesten demografischen Daten und Baustellenplanungen neu zu bewerten. Strategische Prognosen für die Netzplanung werden wöchentlich erstellt, um Trends in der Fahrgastentwicklung frühzeitig zu erkennen und in die Planungen einfließen zu lassen.

Damit die Vorhersagen für die Leitstelle einen praktischen Nutzen haben, müssen sie innerhalb eines engen Zeitfensters von 30 bis 60 Sekunden vorliegen. Dies umfasst den gesamten Prozess von der Datenabfrage bis hin zur Bereitstellung der endgültigen Prognose. Da externe Faktoren wie das Wetter, Veranstaltungen und aktuelle Staumeldungen für die Prognose relevant sind, wird dafür eine automatisierte Feature-Pipeline verwendet, die Rohdaten in Echtzeit in nutzbare Vektoren transformiert.

Um die anfallende Datenlast effektiv und zeitnah verarbeiten zu können, wird eine skalierbare Infrastruktur genutzt. Für die Inferenz werden skalierbare cloudbasierte Instanzen verwendet die bei hoher Last automatisch Kapazitäten hinzuschalten. Um die Latenz zusätzlich zu senken, wird geprüft, ob eine einfache Vorverarbeitung der Zählsensordaten direkt in den Fahrzeugen erfolgen kann, bevor sie an den zentralen Server übertragen werden. Die wöchentlichen Batch-Verarbeitungen erfordern einen hohen Datendurchsatz der Datenbankserver, da historische GTFS-Daten mit aktuellen Sensordaten über Monate hinweg korreliert werden, um saisonale Muster zu identifizieren.

2.6 Data Collection

Wie wird der erste Satz an Daten und Ergebnissen gewonnen (z. B. Datenbank-Extrakte, APIs, manuelle Beschriftung)? Zudem wird die Strategie zur kontinuierlichen Aktualisierung der Daten unter Berücksichtigung von Kosten und Aktualität beschrieben.

Die Datenbeschaffung folgt einem hybriden Ansatz, der sowohl interne Betriebsdaten als auch externe Faktoren integriert, um eine präzise Bedarfsprognose zu ermöglichen. Die Datensammlung besteht aus vier Hauptkategorien, um die Vorhersage der Auslastung der Liniensegmente zu ermöglichen. Die primäre Datenquelle sind die im Innenraum der Fahrzeuge verbauten automatischen Fahrgastzählsysteme (AFZ). Diese Systeme liefern für jede Haltestelle die Anzahl der Ein- und Ausstiege und die Gesamtauslastung. Diese Sensordaten bilden die Grundlage der Vorhersage. Daten aus den Fahrkartenverkäufen über die SWU- und DING-App, sowie der Automaten in den Fahrzeugen liefern Informationen über Start und Ziel der gewünschten Fahrten. Während Sensoren nur den aktuellen Ist-Zustand erfassen, erlauben diese Ticketdaten einen Rückschluss auf die beabsichtigten Reisewege der Fahrgäste. Suchanfragen in der Fahrplanauskunft der Apps erlauben es, Zustimmung der Nutzer vorausgesetzt, die anonymisierten GPS-Standorte zum Zeitpunkt der Abfrage zu erfassen und latente Bedarfe zu identifizieren. Dies erlaubt Rückschlüsse auf Orte, die durch das aktuelle Liniennetz eventuell noch nicht optimal abgedeckt sind. An Infrastruktur- und Kontextdaten werden die statischen GTFS-Daten zu Haltestellen und Fahrplänen benötigt, sowie dynamische Datenfeeds zu Baustellen und Großveranstaltungen . Um den entsprechenden Datenschutzvorgaben zu genügen, werden GPS-Daten und App-Interaktionen anonymisiert und aggregiert, um keine Rückschlüsse auf Einzelpersonen zuzulassen.

Um sowohl kurzfristige operative als auch langfristige taktische Entscheidungen zu unterstützen, erfolgt die Datenerhebung in unterschiedlichen Zeiträumen. Die GPS-Positionsdaten und aktuelle Sensordaten der Fahrzeuge werden im 30-Sekunden-Takt an den zentralen Data Lake übertragen, um Kurzfristprognosen zu ermöglichen. Historische Daten der Fahrzeugsensoren und Ticketverkäufe werden täglich aggregiert und für das erneute Training des Modells aufbereitet. Dies ist essentiell für die Identifikation von saisonalen Trends und die Planung von Ersatzverkehren bei Baustellen.

Die Qualität der Daten wird durch die folgenden Maßnahmen sichergestellt. Ausreisser in den Sensordaten, wie zum Beispiel bei Fehlmessungen durch blockierte Türen, werden durch einen statischen Filter geglättet. Da verschiedene Fahrzeugtypen wie Standardbus, Gelenkbus, Straßenbahn, unterschiedliche Kapazitäten haben, wird die absolute Personenzahl an Bord durch eine relative Auslastung normalisiert, um einen objektiven Vergleich zu ermöglichen.

2.7 Data Sources

Für die Realisierung eines bedarfsorientierten ÖPNV-Modells ist eine belastbare und vielschichtige Datenbasis unumgänglich. Wir differenzieren hierbei zwischen den primären Betriebsdaten der SWU Verkehr GmbH, Mobilitätsdaten des regionalen Verkehrsverbundes DING, sowie externe Kontextdaten, um sowohl historische Muster als auch dynamische Einflussfaktoren präzise abzubilden.

Die internen Betriebsdaten bilden das Rückgrat der Analyse und liefern die IST-Werte für das Training der Regressionsmodelle. Das Automaitsche Fahrgastzählsystem (AFZ) in den Fahrzeugen liefert hochpräzise Daten über Ein- und Ausstiege an jeder Haltestelle sowie die gesamtauslastung- Diese Sensordaten sind die objektivste Datenquelle zur Bestimmung der tatsächlichen Auslastung pro Liniensegment. Aus den Daten des Betriebsleitsystems beziehen wir Echtzeitinformationen über die aktuelle Position der Fahrzeuge, Verspätungen und Fahrtausfälle. Diese Daten sind insbesondere für die kurzfristige Vorhersage zur Reaktion auf Stauereignisse kritisch. Die statischen Daten des Liniennetzes inklusive aller Haltestellenkoordinaten und Taktzeiten werden über die General Transit Feed Specification (GTFS) integriert.

Um die Nachfrage besser zu verstehen, nutzen wir Daten, um Rückschlüsse auf gewünschte Routen zuzulassen. Daten aus Ticketverkäufen über die SWU- und Ding-Apps sowie Fahrkartenautomaten geben Aufschluss über das Kaufverhalten und geplante Fahrten. Digitale Tickets aus den Apps ermöglichen zudem eine anonymisierte Analyse der tatsächlichen Startpunkte. Suchanfragen in der Fahrplanauskunft dienen als frühzeitiger Indikator für die kommende Nachfrage. Bei entsprechender Zustimmung der Nutzer können GPS-Standorte zum Zeitpunkt der Anfrage genutzt werden, um den Bedarf auch abseits bestehender Haltestellen zu identifizieren.

Da die ÖPNV-Auslastung stark von äußeren Faktoren abhängt, verwenden wir externe dynamische Datenquellen, um die Präzision der Vorhersage zu erhöhen. Informationen der Stadtverwaltungen Ulm und Neu-Ulm zu Baustellen sind essentiell um deren Auswirkungen auf die Taktstabilität zu bewerten. Für die Vorhersage von Nachfragespitzen werden Daten zu Veranstaltungen aus Veranstaltungskalendern automatisiert eingelesen. Meteorologische Daten werden als Feature genutzt, da das Fahrgastverhalten signifikant mit der aktuellen Wetterlage korreliert. Demografische und städtebauliche Daten der Stadt Ulm werden für die mittelfristige Planung verwendet, um auf das Wachstum einzelner Stadtteile reagieren zu können.

Die Kombination aus fahrzeuggebundenen Zählsensoren und digitalen Nutzerdaten minimiert den Bias in der Vorhersage. Während die Sensordaten die Basis für die Evaluierung bilden, ermöglichen die Kontextdaten ein proaktives Handeln der Leitstelle noch bevor operative Kapazitätsengpässe auftreten.

2.8 Building Models

Für die erfolgreiche Umsetzung der bedarfsorientierten ÖPNV-Steuerung setzen wir auf eine mehrstufige Modellarchitektur. Ziel ist es, die Komplexität des städtischen Verkehrsflusses abzubilden und gleichzeitig eine hohe Reaktionsgeschwindigkeit für die Leitstelle zu gewährleisten.

Um die unterschiedlichen Zeitrahmen, von der 5-minütigen Echtzeitprognose bis zur 6-monatigen strategischen Planung, abzudecken, kommen verschiedene Modelltypen zum Einsatz. Für die Echtzeitvorhersage der Fahrzeugauslastung werden Modelle benötigt, die eine geringe Latenz bei der Inferenz (unter 60 Sekunden) aufweisen und heterogene tabellarische Daten wie Sensordaten, Zeitstempel, und Wetterdaten, effizienz verarbeiten können. Die gewählte Architektur muss in der Lage sein, lokale Muster einzelner Liniensegmente zu lernen, während sie gleichzeitig ein stabiles Basismodell für das gesamte Netz bietet. Wir benötigen ein zentrales Basismodell, das jedoch linien- und fahrzeugspezifische Features nutzt, um die Besonderheiten einzelner Segmente zu berücksichtigen.

Die Modellierung der mittelfristigen Planung stellt zwei Kernanforderungen. Zum einen müssen langfristige zeitliche Abhängigkeiten und Saisonalitäten, wie zum Beispiel Auswirkungen von Großbaustellen über Monate hinweg, abgebildet werden. Zum anderen erfordert die Netzstruktur eine Architektur, welche die topologische Verbundenheit des Liniennetzes, mit Haltestellen als Knoten und Strecken als Kanten, mathematisch berücksichtigt, um räumliche Nebenwirkungen bei Netzveränderungen präzise zu simulieren. Da das Liniennetz als Graph strukturiert ist, mit Haltestellen als Knoten und Streckensegmenten als Kanten, ermöglicht dies eine präzise Simulation von Netzveränderungen wie z.B. bei der Anbindung neuer Haltestellen.

Die Aktualität der Modelle ist entscheidend, um auf dynamische Entwicklungen reagieren zu können. Die Kurzfrist-Modelle werden jede Nacht mit den aggregierten Sensordaten des Vortages aktualisiert. Dies stellt sicher, dass kurzfristige Trends, wie z.B. ein verändertes Nutzerverhalten durch neue Baustellen, sofort in die Prognose mit einfließen. Die komplexen LSTM- und GNN-Modelle werden wöchentlich auf dem gesamten historischen Datensatz neu trainiert. Hierbei werden auch externe Datenquellen wie aktualisierte Baustellenpläne und Veranstaltungskalender integriert. Alle drei Monate findet ein umfassendes Audit der Modellgüte statt, um sicherzustellen, dass kein Datendrift durch dauerhafte Änderungen im Mobilitätsverhalten die Vorhersagequalität mindert.

Für die Erstellung und Analyse der Modelle kalkulieren wir die folgenden Ressourcen ein. Für das Training der Deep-Learning-Modelle nutzen wir GPU-unterstützte Cloud-Instanzen. Ein vollständiger Trainingsdurchlauf für das gesamte Liniennetz darf aufgrund der wöchentlichen Zyklen eine Dauer von 12 Stunden nicht überschreiten. Die produktive Umgebung muss in der Lage sein, Vorhersagen innerhalb von maximal 60 Sekunden bereitzustellen. Hierfür kommt eine skalierbare Container-Lösung zum Einsatz, die je nach Auslastung zusätzliche Rechenkapazität dynamisch zuteilen kann. Ein zentraler Datensee fungiert als Quelle wobei die Vorverarbeitung der Rohdaten aus den Fahrzeugen automatisiert erfolgt, um Bias durch Sensorausfälle oder -fehlfunktionen zu minimieren.

Die Entwicklungsphase für die Modellierung ist auf insgesamt 4 Monate angesetzt. Davon entfallen 6 Wochen auf die Feature-Extraktion und das initiale Training der Basismodelle. Die restliche Zeit dient der Feinabstimmung der Hyperparameter und einem 4-wöchigen Parallellauf.

2.9 Features

Im Rahmen des Feature Engineering werden die Rohdaten so transformiert, dass das Modell die komplexen Zusammenhänge städtischer Infrastruktur und Mobilitätsverhalten der Bürger erlernen kann. Wir unterteilen die Features in temporäre, infrastrukturelle, demografische und externe Merkmale, um sowohl die kurzfristige operative Steuerung als auch die langfristige Netzplanung zu ermöglichen.

Um die temporären Schwankungen im Ulmer ÖPNV abzubilden, ist der Zeitpunkt der Nachfrage elementar. Die entsprechenden Zeitstempel werden in 10-Minuten-Intervallen aggregiert. Ebenso essentiell sind der Wochentag, zur Unterscheidung von Werktag und Wochenende, und der Monat, um saisonale Schwankungen wie Touristenströme in den Sommermonaten zu erfassen. Gesetzliche Feiertage, Schulferien sowie lokale Großereignisse werden als binäres Merkmal erfasst. Ebenso müssen Haupt- und Nebenverkehrszeiten integriert werden.

Infrastrukturelle Merkmale beschreiben die physikalische Umgebung und aktuelle Einschränkungen im Liniennetz. Jede Haltestelle muss identifizierbar sein und in Kategorien wie zentraler Knotenpunkt, Gewerbegebiet eingeordnet werden. Ebenso müssen für jede Haltestelle die vorhandenen Umsteigemöglichkeiten erfasst werden. Der Status von Baustellen wird durch Informationen zu Teilsperrungen oder reduzierten Fahrspuren abgebildet.

Um das Wachstum der Stadtteile und damit ihren Bedarf in die Vorhersage einzubeziehen, werden demografische und sozioökonomische Merkmale genutzt. Dabei muss in Bezug auf Einwohnerdichte und Flächennutzung unterschieden werden zwischen Wohn-, Gewerbe- und Industriegebieten. Wachstumsindikatoren wie die Anzahl geplanter Wohneinheiten oder Büroflächen im Einzugsgebiet der einzelnen Haltestellen ermöglichen es, die mittelfristige Nachfrageentwicklung zu prognostizieren.

Externe Features erhöhen die Präzision der Kurzzeitprognose. Wetterdaten, wie etwa Niederschlagsmengen und Temperatur, beeinflussen massiv das Umsteigeverhalten von Fahrrad auf den ÖPNV. Die Verkehrslage des Individualverkehrs, insbesondere Echtzeit-Daten zu bestehenden Staus, werden verwendet um Verspätungen und daraus resultierende Taktinstabilitäten zu prognostizieren. Mit Hilfe digitaler Suchanfragen aus den SWU- und DING-Apps lassen sich Häufungen für bestimmte Verbindungen als Indikatoren für kommende Lastspitzen identifizieren.

Das Modell nutzt zeitverzögerte Werte der Zielvariablen, um Trends zu erkennen. Als historischer Durchschnitt eines Segments dient die durchschnittliche Auslastung der letzten vier Wochen. Dies wird verglichen mit der aktuellen Auslastung des Segments in den letzten 10 Minuten, um plötzliches Verkehrsaufkommen zeitnah zu erfassen.

2.10 Monitoring

Um den langfristigen Erfolg und die Zuverlässigkeit des Modells sicherzustellen, ist ein kontinuierliches und mehrschichtiges Monitoringsystem unerlässlich. Da die Vorhersagen direkt in die operative Steuerung einfließen, müssen wir sicherstellen, dass Abweichungen in der Modellgüte oder Datenqualität sofort erkannt und behoben werden, bevor sie negative Auswirkungen auf den Fahrbetrieb haben.

Das technische Monitoring überwacht die technische Integrität der Datenströme. Da der hybride Ansatz auf Echtzeitdaten aus den Fahrzeugsensoren, GPS-Signalen und App-Interaktionen basiert, ist die kontinuierliche Verfügbarkeit dieser Daten kritisch. Data Drift wird überwacht, indem auf Änderung der statistischen Eigenschaften der Eingangsdaten geachtet wird. Beispielsweise können großflächige Ausfälle des Liniennetzes durch Sperrungen oder Baustellen dazu führen, dass historische Trainingsdaten nicht mehr repräsentativ sind. Die Plausibilitätsprüfung der Zählsensoren erfolgt über eine automatisierte Entscheidungsregel auf Basis historischer Kapazitätsgrenzen. Übermittelt ein Fahrzeug an drei aufeinanderfolgenden Haltestellen Daten, die die physikalische Maximalkapazität des Fahrzeuges um mehr als zehn Prozent überschreiten, oder meldet der Sensor trotz einer via Ticketkauf nachgewiesenen Mindestbelegung über zwei Stunden hinweg konstant keine Fahrgäste, stuft das System diese Daten als systematisch unrealistisch ein. In diesem Fall greift die Regel dass die Werte des betroffenen Fahrzeuges innerhalb von sechzig Sekunden aus der Inferenzpipeline ausgeschlossen werden und im Flottenmanagementsystem ein priorisiertes Wartungsticket generiert wird. Für die Inferenz ist eine Dauer von 30 bis 60 Sekunden definiert. Um die Handlungsfähigkeit der Disponenten in der Leitstelle nicht zu gefährden, werden bei Überschreitung dieser Schwelle sofort die entsprechenden IT-Verantwortlichen informiert.

Die Vorhersagegüte des Modells wird im laufenden Betrieb permanent gegen die tatsächlich eingetroffenen Werte validiert. als primäre Quelle dienen hierfür die Daten der Zählsensoren, die unmittelbar nach Abschluss eines Liniensegments zur Verfügung stehen. Fällt die durch den F1-Score ermittelte Genauigkeit bei der Identifikation von Überlastung oder Unterbelegung an drei aufeinander folgenden Tagen unter die kritische Grenze von 85 Prozent, löst das Monitoring-System ein automatisches Retraining des Modells mit den Daten der vergangenen vier Wochen aus. Sollte die Modellgüte nach dem abgeschlossenen Trainingszyklus weiterhin unter der Schwelle liegen oder im laufenden Betrieb einen F1-Score von 80% unterschreiten greift die operative Eskalationsregel, welche den automatisierten Vorschlagsmodus für Taktanpassungen deaktiviert, das System in einen statischen Fallback-Modus auf Basis des Regelfahrplans versetzt und eine visuelle Warnmeldung in der Leitstelle generiert. Die Kurzfristprognosen werden auf ihre zeitliche Stabilität hin überwacht. Sollten die Vorhersagen zu volatil werden, sinkt die Akzeptanz durch das Leitstellenpersonal, dies wird durch statistische Glättungsverfahren im Monitoring abgefangen. Besonders kritische Knotenpunkte erhalten ein gesondertes Monitoring um lokale Modellfehler priosiert zu behandeln.

Schlussendlich muss das Modell einen messbaren Mehrwert für die SWU Verkehr GmbH und die Fahrgäste liefern. Wir erfassen, wie oft durch die Vorhersagen Fahrten mit einer Auslastung unter 50% vermieden werden konnten oder durch den Einsatz von

Gelenkbussen Überlastung über 75% Auslastung verhindert wurde. Dies dient als Nachweis der Exzellenz und Kosteneffizienz. Über die Ticketdaten und Feedback aus den Apps überwachen wir indirekt die Auswirkungen auf die Servicequalität. Das Ziel bleibt der Modalsplit, also der Wechsel vom Individualverkehr hin zum ÖPNV. Dies erfolgt durch ein verlässliches und bedarfsorientiertes Angebot.

Die Einhaltung der gesetzlichen Grundversorgung wird durch eine präventive Kontrollregel abgesichert, die direkt in die logische Kette vor der Freigabe jeglicher Optimierungsvorschläge geschaltet ist. Erkennt das System, dass ein Modellvorschlag zur Taktausdünnung die im Regionalisierungs- und Personenbeförderungsgesetz verankerte Mindestfrequenz von 2 Fahrten pro Stunde auf einem Streckensegment unterschreiten würde, greift eine harte Blockierungsregel, die die automatisierte Umsetzung sofort stoppt. Der tägliche automatisierte Bericht dokumentiert diese Vorfälle quantitativ, wobei jede versuchte Unterschreitung der Daseinsvorsorge durch das Modell als Compliance-Warnung erfasst und bei einer Häufung von mehr als fünf Blockierungen pro Woche eine obligatorische Überprüfung der betroffenen Nachfrage-Features erzwingt.

OWNML MACHINE LEARNING CANVAS

Designed for: | Designed by: | Date: | Iteration:

PREDICTION TASK

What is the type of task?
Which entity are predictions made on?
What are the possible outcomes to predict?
When are outcomes observed?

Regression zur Vorhersage der Fahrgastnachfrage pro Liniensegment und Zeitfenster (10-30 Minuten).

Zielvariable: Relative Auslastung (%) und absolute Personenzahl pro Fahrzeug.

DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

Anpassung von Taktzeiten, Linienführungen und Fahrzeugkapazitäten.

Operative Entscheidungen bei Staus (z.B. Umleitungen).

Taktische Planungen von Ersatzverkehren bei Baustellen.

VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed?
How will the ML solution integrate with their workflow, and through which user interfaces?

Transformation von angebots- zu bedarfsorientierter Planung.

Optimierung der Ressourcenallokation (Vermeidung von Leerfahrten/Überlastung).

Erhöhung der Fahrgastzufriedenheit durch kürzere Reisezeiten und bessere Anbindung.

DATA COLLECTION

How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)?
What strategies are in place to update data continuously while controlling cost and maintaining freshness?

Kontinuierliche Datenextraktion aus App-Logs und Sensor-APIs.

Zusammenführung historischer Fahrgastzahlen mit Echtzeit-Bewegungsdaten unter Beachtung des Datenschutzes.

DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

Intern: Fahrplanauskunft-Apps (SWU/DING), Ticketdaten, GPS-Standorte, Zählsensoren in Fahrzeugen.

Extern: GTFS-Daten für Liniennetze, Baustelleninfos der Stadt Ulm.

IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions?
Which data is used to simulate pre-deployment impact?
What are the criteria for deployment?
Are there fairness constraints?

Entscheidungsregel für Leitstelle siehe Kapitel 2.4

rechtliche Vorgaben zur Grundversorgung

4 Wochen Testlauf

Deployment bei F1-Score > 85%

MAKING PREDICTIONS

Are predictions made in batch or in real time?
How frequently?
How much time is available for this (including featurization and decisions)?
Which computational resources are used?

Echtzeit-Vorhersagen (Batch/Stream) alle 15 Minuten für den operativen Betrieb.

Langfristige Simulationen für die strategische Netzplanung.

BUILDING MODELS

How many models are needed in production?
When should they be updated?
How much time is available for this (including featurization and analysis)?
Which computation resources are used?

Echtzeitprognose der Fahrzeugauslastung.

Langzeitprognose zur strategischen Planung.

Regelmäßige Re-Trainingszyklen zur Berücksichtigung neuer Stadtentwicklungen.

FEATURES

What representations are used for entities at prediction time?
What aggregations or transformations are applied to raw data sources?

Historische Auslastungswerte.

Wochentag/Uhrzeit.

Wetterdaten.

Veranstaltungen.

Baustellenstatus.

MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business?
How often should they be reviewed?

Anteil der Fahrten mit >75% und <50% Auslastung.

Durchschnittliche Anzahl Umstiege (Ziel: max. 1).

F1-Score > 85%

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

Strategische ÖPNV-Optimierung Ulm/Neu-Ulm

Bedarfsorientierte Netzplanung durch Predictive Analytics zur Sicherung der Mobilität in Zeiten infrastruktureller Herausforderungen

Die Herausforderung: Status Quo & Risiken

Ineffiziente Auslastung

Diskrepanz zwischen historischen Fahrplänen und realem Bedarf.

Parallele Überlastung und Leerfahrten.

Infrastruktur-Druck

Großbaustellen erfordern proaktive Steuerung statt reaktiver Stauverwaltung.

Attraktivitätsverlust

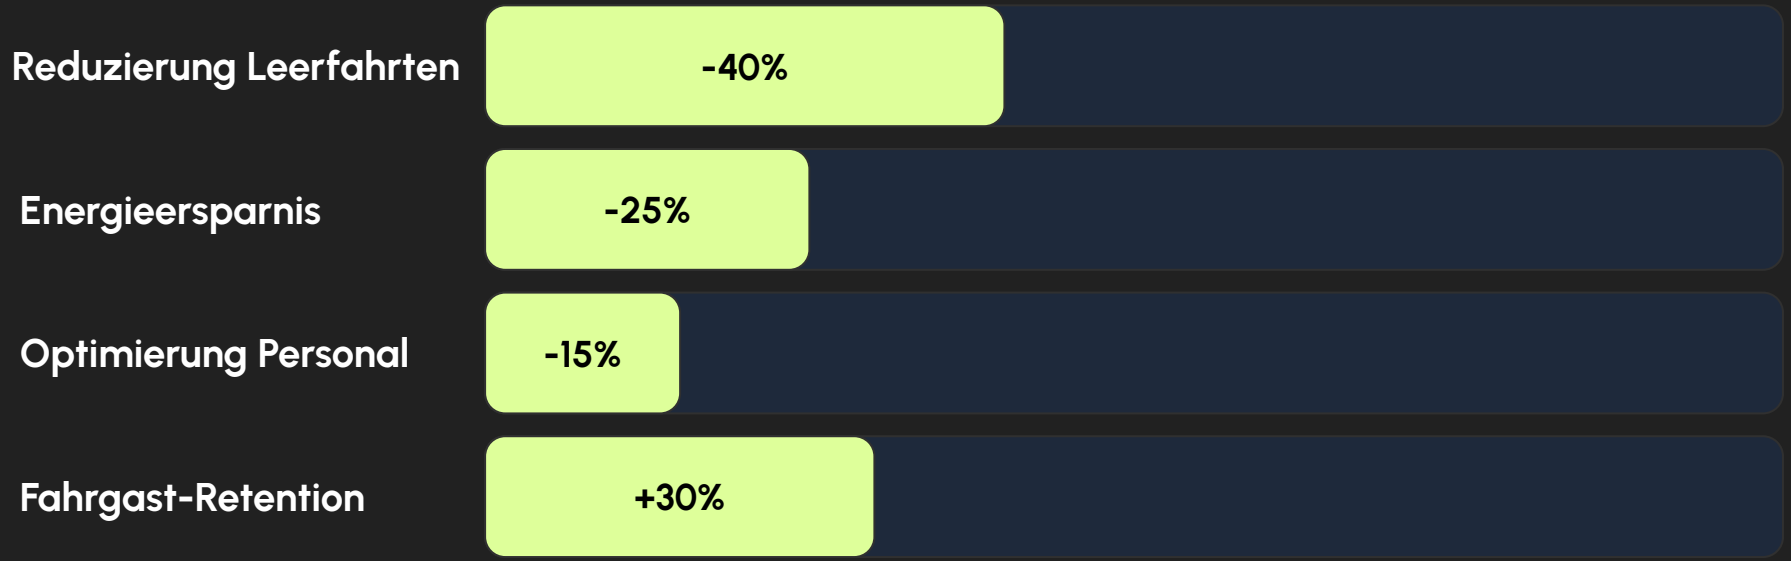
Starre Taktungen und Umstiege führen zu Abwanderungen zum Individualverkehr.

Gefahr für die Mobilitätswende!

Die Lösung: KI-gestützte Bedarfsplanung

- **Echtzeit-Nachfrageprognose**: Vorhersage der Fahrgastzahlen auf Segmentebene alle 5 Minuten.
- **Proaktive Flottensteuerung**: Kurzfristige Anpassung von Fahrzeugkapazitäten (Gelenkbusse) in 1-4 Stundenfenstern.
- **Dynamische Netzplanung**: Wöchentliche Optimierung des Liniennetzes basierend auf Baustellen- und Wetterdaten.
- **Zielvorgabe**: Maximierung der Auslastung zwischen 50% und 75% bei maximal einem Umstieg.

Wirtschaftlicher Impact & Effizienz



Durch die Vermeidung von Fehlplanungen und Überkapazitäten sichern wir die Profitabilität trotz steigender Energiekosten.

Entscheidung: Zukunftssicherer ÖPNV

85%
Prognosegenauigkeit

60s
Reaktionszeit Leitstelle

12 Mo
Amortisationszeitraum

Empfehlung: Freigabe der Pilotphase zur Integration in das Betriebsleitsystem und Validierung der Kosteneinsparungen.

Literaturverzeichnis

Becker, B. (2026, Februar 5). Personenzählung in Bus und Bahn: Der ultimative Leitfaden für den ÖPNV. *Pallax*. https://pallax.io/blog/personenzaehlung-in-bus-und-bahn-der-ultimative-leitfaden-fuer-den-oepnv/

Beinhölzl, C. (o. J.). *Ulm kurz und knapp*. Stadt Ulm - Ulm kurz und knapp. Abgerufen 26. März 2026, von https://www.ulm.de/rathaus/stadtverwaltung/statistiken-offene-daten-und-karten/ulm-kurz-und-knapp

Klemm, D. (2025, März 11). *Starker Tourismus in Ulm und Neu-Ulm*. https://www.donau3fm.de/starker-tourismus-in-ulm-und-neu-ulm-1007707/

Saake, S., Budnitzki, A., & Sommer, C. (2024, März 1). *Auslastungsprognosen im ÖPNV: Wie lässt sich die Qualität von Prognoseergebnissen bewerten?* https://www.researchgate.net/publication/379697047_Auslastungsprognosen_im_OPNV_Wie_lasst_sich_die_Qualitat_von_Prognoseergebnissen_bewerten

Stadt Neu-Ulm. (o. J.). *Stadtinfo—Stadt Neu-Ulm*. Abgerufen 26. März 2026, von https://nu.neu-ulm.de/stadt-politik/stadtinfo

Stadt Ulm. (o. J.). *Ehinger Tor*. Stadt Ulm - Ehinger Tor. Abgerufen 26. März 2026, von https://www.ulm.de/rathaus/stadtpolitik/ulm-baut-um/ehinger-tor

SWU. (2025). *SWU Zahlenspiegel 2024*. https://www.swu.de/fileadmin/content/unternehmen/swu-zahlenspiegel-2024.pdf

Von Poll. (o. J.). *Neubauprojekte in Ulm und Neu-Ulm – Diese Bauvorhaben sollten Interessierte kennen*. Abgerufen 26. März 2026, von https://www.von-poll.com/de/immobilienmakler/ulm/blog/neubauprojekte-in-ulm-und-neu-ulm-diese-bauvorhaben-sollten-interessierte-kennen